



UNIVERSITATEA DIN
BUCUREȘTI

FACULTATEA DE
MATEMATICĂ ȘI
INFORMATICĂ



SPECIALIZAREA INFORMATICĂ

Lucrare de licență

TITLUL LUCRĂRII DE LICENȚĂ

Absolvent

Numele studentului

Coordonator științific

Titlul și numele profesorului coordonatorului

București, iunie 2021

Rezumat

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Fusce vitae eros sit amet sem ornare varius. Duis eget felis eget risus posuere luctus. Integer odio metus, eleifend at nunc vitae, rutrum fermentum leo. Quisque rutrum vitae risus nec porta. Nunc eu orci euismod, ornare risus at, accumsan augue. Ut tincidunt pharetra convallis. Maecenas ut pretium ex. Morbi tellus dui, viverra quis augue at, tincidunt hendrerit orci. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Aliquam quis sollicitudin nunc. Sed sollicitudin purus dapibus mi fringilla, nec tincidunt nunc eleifend. Nam ut molestie erat. Integer eros dolor, viverra quis massa at, auctor.

Abstract

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Fusce vitae eros sit amet sem ornare varius. Duis eget felis eget risus posuere luctus. Integer odio metus, eleifend at nunc vitae, rutrum fermentum leo. Quisque rutrum vitae risus nec porta. Nunc eu orci euismod, ornare risus at, accumsan augue. Ut tincidunt pharetra convallis. Maecenas ut pretium ex. Morbi tellus dui, viverra quis augue at, tincidunt hendrerit orci. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Aliquam quis sollicitudin nunc. Sed sollicitudin purus dapibus mi fringilla, nec tincidunt nunc eleifend. Nam ut molestie erat. Integer eros dolor, viverra quis massa at, auctor.

Cuprins

1	Introducere	4
1.1	Motivație	4
1.2	Problema identificată	4
1.3	Importanța înțelegerii informațiilor nutriționale	5
1.4	Obiectivele aplicației	5
1.5	Contribuții	6
2	Preliminarii	7
2.1	Recunoașterea optică a caracterelor (OCR)	7
2.1.1	Principiile fundamentale ale OCR	7
2.1.2	Tesseract OCR	7
2.2	Inteligența artificială în procesarea limbajului natural	8
2.2.1	Modele de limbaj mari (Large Language Models)	8
2.2.2	Gemini API	8
2.3	Tehnologii web moderne	9
2.3.1	FastAPI	9
2.3.2	PostgreSQL	9
2.4	Containerizare cu Docker	10
2.4.1	Avantajele containerizării	10
2.4.2	Docker Compose	10
2.5	Procesarea imaginilor pentru OCR	10
2.5.1	Pillow (PIL)	11
2.5.2	Optimizări specifice pentru etichete alimentare	11
3	Concluzii	12

Capitolul 1

Introducere

1.1 Motivație

În contextul actual, când conștientizarea asupra importanței unei alimentații sănătoase este în continuă creștere, capacitatea de a înțelege și interpreta corect informațiile nutriționale de pe etichetele alimentelor devine esențială. Această lucrare își propune să dezvolte o soluție tehnologică care să simplifice procesul de analiză a etichetelor nutriționale prin utilizarea tehnologiilor de recunoaștere optică a caracterelor (OCR) și a inteligenței artificiale.

Motivația pentru dezvoltarea acestei aplicații provine din experiența personală acumulată în domeniul culturismului și nutriției. În acest context, înțelegerea precisă a compoziției alimentelor nu este doar o preferință, ci o necesitate. Multe produse alimentare conțin liste complexe de ingrediente, cu denumiri științifice sau tehnice care sunt greu de înțeles pentru consumatorul obișnuit. Aceste ingrediente sunt adesea deliberat denumite folosind terminologia științifică pentru a masca natura lor sau pentru a face lista de ingrediente mai puțin accesibilă publicului larg.

Din experiența personală, a fost necesar în repetate rânduri să explic altor persoane de ce anumite ingrediente sunt benefice sau dăunătoare, deoarece acestea nu reușeau să înțeleagă compoziția produselor pe care le consumau. De asemenea, chiar și pentru o persoană cu experiență în domeniu, interpretarea unor ingrediente necunoscute necesită cercetare suplimentară, ceea ce face procesul de selecție a alimentelor inefficient și consumator de timp.

1.2 Problema identificată

Consumatorii se confruntă cu multiple dificultăți în înțelegerea etichetelor nutriționale:

Complexitatea terminologiei: Ingredientele sunt frecvent listate folosind denumiri științifice în loc de nume comune, făcând dificilă identificarea lor de către consumatori.

De exemplu, acidul ascorbic în loc de vitamina C, sau tocoferoli în loc de vitamina E.

Lungimea listelor de ingrediente: Produsele moderne conțin adesea liste foarte lungi de ingrediente, pe care consumatorii nu au timp sau răbdarea să le analizeze în detaliu.

Ingrediente irelevante prezentate ca importante: Multe produse conțin ingrediente cu nume complexe care în realitate sunt doar arome, coloranți sau conservanți cu impact minimal asupra sănătății, dar care pot intimida consumatorii.

Lipsa contextului: Chiar dacă un consumator recunoaște un ingredient, acesta poate să nu înțeleagă impactul său asupra sănătății sau să aibă informații incomplete sau eronate despre acesta.

1.3 Importanța înțelegerii informațiilor nutriționale

Înțelegerea corectă a ingredientelor și a informațiilor nutriționale este crucială din mai multe perspective:

Sănătatea personală: Cunoașterea compoziției alimentelor permite luarea unor decizii informate despre ce consumăm, contribuind la menținerea unei alimentații echilibrate și sănătoase.

Identificarea gradului de procesare: Diferențierea între alimentele naturale, minimally processed și cele ultra-procesate ajută la alegerea unor opțiuni mai sănătoase.

Gestionarea alergiilor și intoleranțelor: Pentru persoanele cu alergii sau intoleranțe alimentare, înțelegerea precisă a ingredientelor poate fi o chestiune de siguranță.

Demitizarea ingredientelor: Multe ingrediente considerate „periculoase” de publicul larg sunt de fapt inofensive sau chiar benefice, în timp ce altele, considerate sigure, pot avea efecte negative. O analiză obiectivă ajută la luarea unor decizii bazate pe evidențe științifice.

1.4 Obiectivele aplicației

Aplicația dezvoltată în cadrul acestei lucrări își propune să ofere utilizatorilor un portal simplu și eficient pentru gestionarea și analiza informațiilor nutriționale. Obiectivele principale includ:

Digitizarea automată a informațiilor: Utilizarea tehnologiei OCR pentru extragerea automată a informațiilor nutriționale și a listelor de ingrediente din fotografii, eliminând necesitatea introducerii manuale a datelor.

Interpretarea inteligentă a ingredientelor: Implementarea unui sistem bazat pe inteligență artificială care să traducă listele complexe de ingrediente într-un format ușor de înțeles, explicând rolul și impactul fiecărui component.

Evaluarea gradului de procesare: Calcularea unui scor de procesare pentru fiecare aliment, ajutând utilizatorii să identifice rapid produsele mai naturale față de cele ultra-procesate.

Funcționalități avansate de filtrare și comparare: Oferirea de instrumente pentru filtrarea alimentelor după diverse criterii nutriționale (conținut de proteine, sodiu, zahăruri etc.) și posibilitatea de a compara produse similare.

Bază de date colaborativă: Crearea unei platforme unde utilizatorii pot contribui cu informații despre alimente, beneficiind astfel de o bază de date în continuă expansiune.

1.5 Contribuții

Această lucrare aduce următoarele contribuții în domeniul aplicațiilor de analiză nutrițională:

- Dezvoltarea unui sistem integrat care combină OCR-ul pentru limba română și engleză cu procesarea inteligentă a limbajului natural
- Implementarea unui algoritm de evaluare a gradului de procesare a alimentelor bazat pe analiza ingredientelor
- Crearea unei arhitecturi scalabile folosind tehnologii moderne (FastAPI, PostgreSQL, Docker)
- Demonstrarea fezabilității utilizării modelelor de limbaj pentru interpretarea informațiilor nutriționale în limba română

Capitolul 2

Preliminarii

2.1 Recunoașterea optică a caracterelor (OCR)

Recunoașterea optică a caracterelor reprezintă procesul de conversie a imaginilor care conțin text tipărit sau scris de mână în text digital editabil și căutabil. Această tehnologie a evoluat semnificativ în ultimele decenii, de la sistemele simple de recunoaștere a fonturilor fixe la motoare sofisticate capabile să proceseze texte complexe în multiple limbi.

2.1.1 Principiile fundamentale ale OCR

Procesul OCR constă în mai multe etape fundamentale:

Preprocesarea imaginii: Această etapă include operațiuni de îmbunătățire a calității imaginii, cum ar fi corectarea luminozității și contrastului, eliminarea zgomotului și rotirea pentru alinierea corectă a textului.

Segmentarea: Identificarea și separarea regiunilor care conțin text de restul imaginii, urmată de segmentarea în linii, cuvinte și caractere individuale.

Recunoașterea caracterelor: Analiza formei fiecărui caracter și asocierea acestuia cu caracterul corespunzător din alfabetul țintă.

Post-procesarea: Aplicarea de algoritmi de corecție și verificare pentru îmbunătățirea acurateței rezultatului final.

2.1.2 Tesseract OCR

Tesseract este unul dintre cele mai performante și utilizate motoare OCR open-source disponibile în prezent. Dezvoltat inițial de Hewlett-Packard în anii 1980 și ulterior îmbunătățit de Google, Tesseract oferă suport pentru peste 100 de limbi și poate recunoaște text din imagini cu o acuratețe ridicată.

Principalele avantaje ale Tesseract includ:

- **Suport multilingv:** Capacitatea de a procesa simultan texte în multiple limbi, esențială pentru etichetele alimentelor care conțin adesea text în mai multe idiomuri
- **Flexibilitate:** Posibilitatea de configurare pentru diferite tipuri de text și layout-uri
- **Performanță:** Rezultate comparative superioare față de alte soluții open-source în majoritatea testelor de benchmark
- **Comunitate activă:** Dezvoltare continuă și suport din partea unei comunități mari de dezvoltatori

Studii comparative arată că Tesseract obține o acuratețe de peste 90% pentru texte tipărite în condiții bune de iluminare, ceea ce îl face potrivit pentru procesarea etichetelor alimentelor.

2.2 Inteligența artificială în procesarea limbajului natural

Procesarea limbajului natural (NLP) reprezintă domeniul inteligenței artificiale care se ocupă cu interacțiunea între computere și limbajul uman. În contextul acestei aplicații, NLP este utilizat pentru interpretarea și explicarea listelor de ingrediente.

2.2.1 Modele de limbaj mari (Large Language Models)

Modelele de limbaj mari au revoluționat domeniul NLP prin capacitatea lor de a înțelege și genera text într-o manieră similară cu cea umană. Aceste modele sunt antrenate pe volume masive de text și pot efectua diverse sarcini lingvistice fără a fi explicit programate pentru fiecare task.

2.2.2 Gemini API

Google Gemini reprezintă una dintre cele mai avansate familii de modele de limbaj, optimizată pentru o gamă largă de aplicații. Principalele caracteristici care au motivat alegerea Gemini pentru această aplicație includ:

Performanță în domenii specializate: Gemini demonstrează rezultate superioare în interpretarea conceptelor din domeniul științific, inclusiv chimie și biologie, domenii esențiale pentru înțelegerea ingredientelor alimentare.

Multimodalitate: Capacitatea de a procesa nu doar text, ci și imagini, ceea ce poate fi util pentru dezvoltări viitoare ale aplicației.

Accesibilitate: Oferirea unui tier gratuit generos care permite dezvoltarea și testarea aplicației fără costuri semnificative.

Documentație și suport: API-ul Gemini oferă documentație completă și exemple de integrare, facilitând dezvoltarea aplicației.

2.3 Tehnologii web moderne

2.3.1 FastAPI

FastAPI este un framework web modern pentru dezvoltarea de API-uri în Python, caracterizat prin performanță ridicată și ușurință în utilizare. Principalele avantaje care au motivat alegerea FastAPI includ:

Performanță: FastAPI este unul dintre cele mai rapide framework-uri Python disponibile, cu performanțe comparabile cu Node.js și Go, ceea ce este crucial pentru o aplicație care procesează imagini și efectuează apeluri către servicii externe.

Documentație automată: Generarea automată a documentației API-ului în standardele OpenAPI (Swagger), facilitând testarea și integrarea.

Validare automată: Validarea automată a datelor de intrare și ieșire folosind type hints-urile Python, reducând erorile și îmbunătățind robustețea aplicației.

Suport async nativ: Suportul nativ pentru programarea asincronă permite gestionarea eficientă a multiple cereri simultane.

Maturitatea ecosistemului: FastAPI beneficiază de ecosistemul bogat Python și de integrarea facilă cu biblioteci specializate pentru machine learning și procesarea imaginilor.

2.3.2 PostgreSQL

PostgreSQL este un sistem de gestiune a bazelor de date relaționale open-source, cunoscut pentru fiabilitatea și conformitatea cu standardele SQL. Alegerea PostgreSQL pentru această aplicație se bazează pe:

Robustețea și fiabilitatea: PostgreSQL oferă garanții ACID complete și mecanisme avansate de backup și recovery.

Suport pentru tipuri de date complexe: Capacitatea de a stoca și indexa eficient tipuri de date JSON, utile pentru stocarea informațiilor nutriționale structurate.

Extensibilitate: Posibilitatea de a adăuga extensii pentru funcționalități suplimentare, cum ar fi căutarea full-text.

Performanță: Optimizări avansate pentru interogări complexe și indexare eficientă.

Suport pentru text search: Funcționalități native pentru căutarea în text, utile pentru implementarea funcțiilor de căutare după nume de alimente sau ingrediente.

2.4 Containerizare cu Docker

Docker este o platformă de containerizare care permite împachetarea aplicațiilor împreună cu toate dependențele lor într-un container portabil și ușor de distribuit.

2.4.1 Avantajele containerizării

Portabilitate: Containerele Docker rulează identic pe orice sistem care suportă Docker, eliminând problemele de „funcționează pe mașina mea”.

Izolare: Fiecare container rulează în propriul mediu izolat, evitând conflictele între dependențe.

Scalabilitate: Ușurința de scalare orizontală prin adăugarea de noi instanțe de containere.

Simplificarea deployment-ului: Procesul de deployment devine standardizat și automatizabil.

Reproducibilitatea mediului: Mediul de dezvoltare poate fi reprodus exact în producție, reducând erorile legate de diferențele de configurare.

2.4.2 Docker Compose

Docker Compose permite definirea și rularea aplicațiilor multi-container folosind un fișier YAML de configurare. În contextul acestei aplicații, Docker Compose orchestrează:

- Containerul aplicației backend (FastAPI)
- Containerul bazei de date (PostgreSQL)
- Configurarea rețelei și a volumelor pentru persistența datelor
- Configurarea variabilelor de mediu necesare

Această arhitectură containerizată facilitează dezvoltarea locală, testarea și deployment-ul în producție, oferind o bază solidă pentru scalarea viitoare a aplicației.

2.5 Procesarea imaginilor pentru OCR

Pentru ca sistemul OCR să funcționeze optim cu imaginile etichetelor alimentare, este necesară aplicarea unor tehnici de preprocesare a imaginilor.

2.5.1 Pillow (PIL)

Pillow este biblioteca Python standard pentru procesarea imaginilor, oferind funcționalități pentru:

- Redimensionarea și rotirea imaginilor
- Ajustarea contrastului și luminozității
- Conversia între diferite formate de imagine
- Aplicarea de filtre pentru îmbunătățirea calității

2.5.2 Optimizări specifice pentru etichete alimentare

Etichetele alimentare prezintă provocări specifice pentru OCR:

Fonturi mici: Informațiile nutriționale sunt adesea tipărite cu fonturi foarte mici, necesitând tehnici de scaling și sharpening.

Reflexii și umbre: Materialele reflectorizante ale ambalajelor pot crea reflexii care interferează cu recunoașterea textului.

Fundal colorat: Multe etichete au fundal colorat sau texturi care pot reduce contrastul textului.

Layout complex: Informațiile sunt organizate în tabele și coloane, necesitând detectarea corectă a structurii layout-ului.

Capitolul 3

Concluzii